mencoba ekstraksi cepat menggunakan **spider_rs** terlebih dahulu, beralih secara otomatis ke **Scrapling StealthyFetcher** (untuk melewati Cloudflare Turnstile dan merelokasi elemen adaptif 12-faktor), dan menggunakan server internal **Crawl4AI** sebagai jalur terakhir.

```
import asyncio
import random
import httpx
from typing import List, Optional

class MultiPathProxyAndScraperEngine:
    """
    Mesin Rotasi Proksi & Akuisisi Web Multi-Jalur Otomatis.
    Tidak bergantung pada satu sumber proksi maupun satu pustaka web
scraper.
    """
    def __init__(self, local_pool_url: str = "http://127.0.0.1:5010"):
        self.local_pool_url = local_pool_url
        # Rantai Umpan Proksi Berjenjang: CDN Mirrors -> GitHub Raw ->
Public APIs
        self.proxy_feed_chains: List[str] = [

"https://cdn.jsdelivr.net/gh/monosans/proxy-list@main/proxies/http.txt
",

"https://fastly.jsdelivr.net/gh/jetkai/proxy-list@main/online-proxies/
txt/proxies-http.txt",

"https://fastly.jsdelivr.net/gh/roosterkid/openproxylist@main/HTTPS_RA
W.txt",

"https://raw.githubusercontent.com/TheSpeedX/PROXY-List/master/http.tx
t",

"https://raw.githubusercontent.com/BlackSnowDot/proxylist-update-every
-minute/main/http.txt",

"https://raw.githubusercontent.com/clarketm/proxy-list/master/proxy-li
st-raw.txt",

"https://raw.githubusercontent.com/ShiftyTR/Proxy-List/master/http.txt
",

"https://raw.githubusercontent.com/UptimerBot/proxy-list/main/proxies/
http.txt",

"https://raw.githubusercontent.com/RX4096/proxy-list/main/online/http.
txt",

"https://raw.githubusercontent.com/mmpx12/proxy-list/master/http.txt",
```

```
"https://api.proxyscrape.com/v2/?request=displayproxies&protocol=http&
timeout=5000&country=all",
            "https://www.proxy-list.download/api/v1/get?type=http",
            "https://api.openproxylist.xyz/http.txt"
        ]
        self.verified_proxies: List[str] = []

    async def get_working_proxy(self) -> Optional[str]:
        """Mengambil proksi dari daemon Redis lokal, otomatis failover
ke 13 umpan publik."""
        async with httpx.AsyncClient(timeout=4.0) as client:
            # Jalur 1: Coba daemon lokal jhao104/proxy_pool terlebih
dahulu
            try:
                resp = await client.get(f"{self.local_pool_url}/get/")
                if resp.status_code == 200 and "proxy" in resp.json():
                    return f"http://{resp.json()['proxy']}"
            except Exception:
                pass

            # Jalur 2: Jika kolam memori kosong, panen dari rantai CDN
& GitHub Raw secara acak
            if not self.verified_proxies:
                feeds = random.sample(self.proxy_feed_chains, k=min(4,
len(self.proxy_feed_chains)))
                for feed_url in feeds:
                    try:
                        r = await client.get(feed_url)
                        if r.status_code == 200:
                            lines = [
                                line.strip().split()[0]
                                for line in r.text.splitlines()
                                if ":" in line and not
line.startswith("#")
                            ]
                            self.verified_proxies.extend(lines[:150])
                    except Exception:
                        continue

            if self.verified_proxies:
                chosen = random.choice(self.verified_proxies)
                return f"http://{chosen}"
        return None

    async def report_dead_proxy(self, proxy_url: str) -> None:
        """Menghapus proksi mati dari memori dan melaporkannya ke
jhao104/proxy_pool."""
```

```
        raw_host = proxy_url.replace("http://",
"").replace("https://", "")
        if raw_host in self.verified_proxies:
            self.verified_proxies.remove(raw_host)
        try:
            async with httpx.AsyncClient(timeout=2.0) as client:
                await
client.get(f"{self.local_pool_url}/delete/?proxy={raw_host}")
        except Exception:
            pass

    async def scrape_with_rolling_fallback(self, target_url: str,
css_selector: str = "body") -> str:
        """
        Ekstraksi Web 3-Tingkat:
        Tier 1: Spider-RS (Rust HTTP/Smart Chrome Streaming)
        Tier 2: Scrapling StealthyFetcher (Cloudflare Turnstile Bypass
+ Adaptive 12-Factor Relocation)
        Tier 3: Crawl4AI Internal Docker Service (Isolated Network)
        """
        proxy = await self.get_working_proxy()

        # TIER 1: Spider-RS (Kecepatan Ekstrem Berbasis Rust)
        try:
            import spider_rs
            website = spider_rs.Website(target_url)
            website.crawl()
            pages = website.get_pages()
            if pages and len(pages[0].get_content()) > 100:
                return pages[0].get_content()
        except Exception:
            pass

        # TIER 2: Scrapling StealthyFetcher (Anti-Bot Bypass &
Adaptive Element Tracking)
        try:
            from scrapling.fetchers import StealthyFetcher
            StealthyFetcher.adaptive = True
            page = await StealthyFetcher.async_fetch(
                target_url,
                headless=True,
                network_idle=True,
                proxy=proxy
            )
            elements = page.css(css_selector, adaptive=True)
            if elements:
                return "\n".join([el.text for el in elements if
el.text])
```

```
        except Exception:
            if proxy:
                await self.report_dead_proxy(proxy)

        # TIER 3: Fallback ke Crawl4AI Internal Endpoint (Tanpa Ekspos
Publik untuk Cegah SSRF)
        async with httpx.AsyncClient(timeout=25.0) as client:
            resp = await client.post(
                "http://127.0.0.1:11235/crawl",
                json={"urls": [target_url], "priority": 10}
            )
            resp.raise_for_status()
            return resp.json().get("results", [{}])[0].get("markdown",
"")
```

3. Orkestrator Inferensi LLM, Keamanan ModelScan & Multimodal Auto-Rolling

Kode di bawah ini mengimplementasikan logika inti yang memastikan setiap permintaan kognitif maupun multimodal dari agen memiliki jalan keluar berlapis. Sebelum model lokal dimuat, fungsi verify_model_security() menjalankan protectai/modelscan secara terprogram untuk memblokir serangan serialisasi pickle. Selama waktu jalan (*runtime*), execute_llm_with_rolling() menghitung kompleksitas prompt dan merutekannya melintasi penyedia cloud gratis tanpa kartu kredit (Kelompok 2A), lalu beralih otomatis ke agregator lokal (OmniRoute dan 9Router) serta mesin GGUF tanpa sensor (llama.cpp dan Ollama dengan bobot huihui-ai atau DeepSeek-R1-0528-Qwen3-8B) apabila kuota eksternal habis.

```
import os
import subprocess
import time
from dataclasses import dataclass
from typing import Dict, List, Optional
import httpx

@dataclass
class ProviderEndpoint:
    name: str
    base_url: str
    api_key_env: str
    default_model: str
    tier: str  # "LOCAL_SOTA", "FREE_CLOUD", "AGGREGATOR", "WHOLESALE"
    cooldown_until: float = 0.0

class AutonomousRollingOrchestrator:
    """
    Orkestrator Inferensi Multi-Jalur dengan Circuit Breaker Otomatis,
    Perutean Ambang Batas Kompleksitas (RouteLLM tau=0.11593), dan
```

```
Audit ModelScan.
    """
    def __init__(self):
        self.tau_threshold = float(os.getenv("ROUTELLM_THRESHOLD",
"0.11593"))
        self.endpoints: List[ProviderEndpoint] = [
            # Jalur Cepat & Tanpa Sensor Lokal (Biaya Rp 0, Privasi
100%)
            ProviderEndpoint(
                name="LlamaCpp_Local_Abliterated",
                base_url=os.getenv("LLAMA_CPP_LOCAL_URL",
"http://127.0.0.1:8080/v1"),
                api_key_env="NONE",
                default_model=os.getenv("LOCAL_UNCENSORED_MODEL",
"huihui-ai/Huihui-Qwen3.8-27B-abliterated-GGUF"),
                tier="LOCAL_SOTA"
            ),
            ProviderEndpoint(
                name="Ollama_Local_Reasoning",
                base_url=os.getenv("OLLAMA_LOCAL_URL",
"http://127.0.0.1:11434/v1"),
                api_key_env="NONE",
                default_model="deepseek-ai/DeepSeek-R1-0528-Qwen3-8B",
                tier="LOCAL_SOTA"
            ),
            # Jalur Agregator Mandiri (150+ Penyedia Gratis &
Konverter CLI)
            ProviderEndpoint(
                name="OmniRoute_Gateway",
                base_url=os.getenv("OMNIROUTE_BASE_URL",
"http://127.0.0.1:4000/v1"),
                api_key_env="SESSION_SECRET",
                default_model="auto-free",
                tier="AGGREGATOR"
            ),
            ProviderEndpoint(
                name="9Router_Coding_Bridge",
                base_url=os.getenv("NINEROUTER_BASE_URL",
"http://127.0.0.1:4001/v1"),
                api_key_env="SESSION_SECRET",
                default_model="claude-code-free",
                tier="AGGREGATOR"
            ),
            # Jalur Cloud Gratis 100% Tanpa Kartu Visa (Kelompok 2A -
Terverifikasi 2026)
            ProviderEndpoint(
                name="Google_AI_Studio_Gemini",
```

```
base_url="https://generativelanguage.googleapis.com/v1beta/openai",
                api_key_env="GEMINI_API_KEY",
                default_model="gemini-3.5-flash",
                tier="FREE_CLOUD"
            ),
            ProviderEndpoint(
                name="Mistral_Experiment_1B_Pool",
                base_url="https://api.mistral.ai/v1",
                api_key_env="MISTRAL_API_KEY",
                default_model="mistral-large-latest",
                tier="FREE_CLOUD"
            ),
            ProviderEndpoint(
                name="Groq_LPU_Fast",
                base_url="https://api.groq.com/openai/v1",
                api_key_env="GROQ_API_KEY",
                default_model="qwen-qwq-32b",
                tier="FREE_CLOUD"
            ),
            ProviderEndpoint(
                name="OpenRouter_Dynamic_Free",
                base_url="https://openrouter.ai/api/v1",
                api_key_env="OPENROUTER_API_KEY",
                default_model="openrouter/free",
                tier="FREE_CLOUD"
            ),
            ProviderEndpoint(
                name="NVIDIA_NIM_91_Free",
                base_url="https://integrate.api.nvidia.com/v1",
                api_key_env="NVIDIA_NIM_API_KEY",
                default_model="deepseek-ai/deepseek-r1",
                tier="FREE_CLOUD"
            ),
            # Jalur Cadangan Grosir Berbasis Crypto USDT / Kredit
Pendaftaran (Kelompok 3A)
            ProviderEndpoint(
                name="SiliconFlow_Cloud",
                base_url="https://api.siliconflow.cn/v1",
                api_key_env="SILICONFLOW_API_KEY",
                default_model="deepseek-ai/DeepSeek-V3",
                tier="WHOLESALE"
            ),
            ProviderEndpoint(
                name="Novita_AI_USDT_Fallback",
                base_url="https://api.novita.ai/v3/openai",
                api_key_env="NOVITA_API_KEY",
                default_model="deepseek/deepseek-r1",
                tier="WHOLESALE"
```

```
            )
        ]

    @staticmethod
    def verify_model_security(model_path: str) -> bool:
        """
        Gerbang Zero-Trust: Memastikan berkas model adalah
.safetensors / .gguf
        atau lulus audit statis ProtectAI ModelScan (Exit Code 0).
        """
        if model_path.endswith((".safetensors", ".gguf")):
            return True
        res = subprocess.run(
            ["modelscan", "-p", model_path],
            capture_output=True,
            text=True,
            check=False
        )
        if res.returncode == 0:
            return True
        raise PermissionError(
            f"ModelScan memblokir pemuatan berkas '{model_path}' (Exit
Code {res.returncode}). "
            "Terdeteksi potensi instruksi berbahaya pada serialisasi
Pickle/H5!"
        )

    def _order_candidates(self, complexity_score: float,
require_uncensored: bool) -> List[ProviderEndpoint]:
        """Menyusun urutan prioritas penyedia berdasarkan skor
RouteLLM dan kebutuhan sensor."""
        now = time.time()
        active = [ep for ep in self.endpoints if ep.cooldown_until <=
now]
        if require_uncensored:
            # Prioritaskan model abliterated lokal dan agregator tanpa
filter
            priority = {"LOCAL_SOTA": 0, "AGGREGATOR": 1, "WHOLESALE":
2, "FREE_CLOUD": 3}
        elif complexity_score < self.tau_threshold:
            # Kueri ringan/menengah (< 0.11593) langsung diselesaikan
di lokal untuk hemat kuota
            priority = {"LOCAL_SOTA": 0, "FREE_CLOUD": 1,
"AGGREGATOR": 2, "WHOLESALE": 3}
        else:
            # Kueri kompleks (>= 0.11593) gunakan kuota gratis Cloud
Frontier -> Agregator -> Lokal
            priority = {"FREE_CLOUD": 0, "AGGREGATOR": 1,
```

```
"LOCAL_SOTA": 2, "WHOLESALE": 3}
        return sorted(active, key=lambda ep: priority.get(ep.tier,
99))

    async def execute_llm_with_rolling(
        self,
        prompt: str,
        system_prompt: str = "You are a helpful autonomous engineering
agent.",
        complexity_score: float = 0.5,
        require_uncensored: bool = False
    ) -> Dict[str, str]:
        """
        Mengeksekusi panggilan LLM dengan pengalihan otomatis
(Auto-Rolling).
        Jika satu penyedia mengembalikan HTTP 429 (Rate Limit) atau
5xx,
        penyedia tersebut dimasukkan ke masa tenang (cooldown) dan
kueri langsung
        dilempar ke penyedia berikutnya dalam hitungan milidetik.
        """
        candidates = self._order_candidates(complexity_score,
require_uncensored)
        errors = []

        async with httpx.AsyncClient(timeout=45.0) as client:
            for ep in candidates:
                api_key = "none" if ep.api_key_env == "NONE" else
os.getenv(ep.api_key_env, "")
                if ep.api_key_env != "NONE" and not api_key:
                    continue

                headers = {
                    "Authorization": f"Bearer {api_key}",
                    "Content-Type": "application/json"
                }
                payload = {
                    "model": ep.default_model,
                    "messages": [
                        {"role": "system", "content": system_prompt},
                        {"role": "user", "content": prompt}
                    ],
                    "temperature": 0.2
                }

                try:
                    resp = await client.post(
                        f"{ep.base_url.rstrip('/')}/chat/completions",
```

```
                        headers=headers,
                        json=payload
                    )
                    if resp.status_code == 200:
                        data = resp.json()
                        content =
data["choices"][0]["message"]["content"]
                        return {
                            "provider_used": ep.name,
                            "model_used": ep.default_model,
                            "response": content
                        }
                    elif resp.status_code in (401, 402, 403, 404, 429,
500, 502, 503, 504):
                        # Aktifkan Circuit Breaker Cooldown selama 120
detik untuk endpoint yang gagal
                        ep.cooldown_until = time.time() + 120.0
                        errors.append(f"{ep.name}: HTTP
{resp.status_code}")
                        continue
                except Exception as exc:
                    ep.cooldown_until = time.time() + 60.0
                    errors.append(f"{ep.name}: {type(exc).__name__}")
                    continue

        raise RuntimeError(f"Seluruh jalur inferensi gagal dieksekusi.
Rincian: {'; '.join(errors)}")
```

4. Matriks Aturan Failover Multimodal, Database, dan Pembayaran untuk Agen AI

Selain inferensi teks dan perayapan web, agen pemrograman wajib mengimplementasikan rantai pengalihan yang sama pada lapisan sintesis media, penyimpanan status, dan kasir pembayaran otomatis menggunakan aturan deterministik berikut:

Komponen Sistem	Jalur Primer (Tier 1)	Jalur Sekunder (Tier 2 — Auto-Rollover)	Jalur Tersier / Lokal (Tier 3 — Zero-Dependency Fallback)	Kondisi Pemicu Pengalihan (Trigger Condition)
Sintesis Suara (TTS) & Voice Cloning	fishaudio/fish-speech (S2-Pro 4B / Drama 3 MoE 35B-A3B via SGLang-Omni)	QwenAudio/CosyVoice (Fun-CosyVoice 3.0 via vLLM 0.11.x+) atau SWivid/F5-TTS	hexgrad/Kokoro-82M (CPU Apache-2.0) \rightarrow OHF-Voice/piper1-gpl / k2-fsa/sherpa-onnx (C++ ONNX)	Latensi TTFA > 500ms, kehabisan VRAM GPU lokal, atau kegagalan daemon PyTorch.

Komponen Sistem	Jalur Primer (Tier 1)	Jalur Sekunder (Tier 2 — Auto-Rollover)	Jalur Tersier / Lokal (Tier 3 — Zero-Dependency Fallback)	Kondisi Pemicu Pengalihan (Trigger Condition)
Generasi Video & Animasi Avatar	Lokal: Wan2.2-TI2V-5B / HunyuanVideo-1.5 (4–12 langkah + TeaCache + SageAttention)	Lokal VRAM Rendah (8–10 GB): LTX-VideoQ8 / HunyuanVideo-Avatar (via Wan2GP)	Cloud Gratis/Grosir: Modal ($30/bln gratis) \rightarrow Pollinations AI (Mode 1) \rightarrow Fal.ai / WaveSpeed / Novita	Penggunaan VRAM melampaui kapasitas fisik kartu grafis lokal atau antrean render > 180 detik.
Database Transaksional & Memori Agen	Turso Cloud (5 GB libSQL Concurrent Writes) + Mem0 (@mem0/cli)	Supabase (500 MB PostgreSQL + pgvector) + Letta (@letta-ai/letta-client)	Neon Serverless Postgres (500 MB) \rightarrow SQLite / Valkey Lokal pada disk VPS	Batas koneksi konkuren tercapai, waktu respons kueri > 200ms, atau pemeliharaan jaringan cloud.
Object Storage Media & Bobot	Cloudflare R2 / Supabase Storage (1 GB Gratis)	Backblaze B2 (10 GB Pertama 100% Gratis Tanpa Kartu Visa)	Penyimpanan Sistem Berkas Lokal Terkompresi (mksglu/context-mode)	Kuota penyimpanan 1 GB penuh atau kegagalan unggah objek HTTP 5xx.
Kasir Pembayaran Otomatis (Treasury)	Paka[span_72](start_span)[span_72](end_span)sir (QRIS Otomatis Indonesia Tanpa Kartu Visa)	Tripay \rightarrow Duitku (Alternatif QRIS Lokal)	Telegram @CryptoBot (Kasir Crypto Pay USDT Global 1-Klik)	Webhook pembayaran QRIS primer tidak merespons dalam 3.000ms atau transaksi berasal dari pembeli internasional.

Kesimpulan dan Rekomendasi Arsitektural

Sintesis komprehensif terhadap seluruh 199 tautan dari ketiga dokumen sumber induk beserta puluhan repositori dan titik akhir alternatif dari riset terbaru membuktikan bahwa ketahanan sistem AI otonom berbiaya nol hanya dapat dicapai melalui abstraksi perutean berlapis yang memberikan imunitas terhadap kepunahan titik akhir (*endpoint extinction immunity*). Perubahan drastis kebijakan penyedia cloud sepanjang paruh kedua tahun 2026—seperti berhentinya layanan GitHub Models pada akhir Juli, peralihan Cerebras ke sistem uji coba berbayar untuk akun baru pada pertengahan Juli, dan penghapusan model Llama lama dari paket gratis Groq pada bulan Agustus—menegaskan bahwa setiap titik akhir eksternal bersifat sementara. Dengan menggabungkan penyedia kuota gratis permanen berkapasitas masif seperti **Mistral Experiment Tier** (~1 miliar token/bulan), **Google AI Studio** (konteks 1 juta token pada Gemini 3.5 Flash), **NVIDIA NIM** (91 model pada 40 RPM), dan **Cloudflare Workers AI** (10.000 Neurons/hari) di belakang agregator lokal (OmniRoute, 9Router, New-API Horizon, dan Portkey Gateway), agen AI dapat terus beroperasi tanpa gangguan meskipun satu atau beberapa

penyedia hulu menutup layanannya secara mendadak.
Pada saat yang sama, kemandirian kognitif dan kepatuhan instruksi penuh kini dapat diwujudkan secara lokal melalui perpaduan antara model penalaran hasil distilasi kompak dan teknik *abliteration* selektif. Ketersediaan model **DeepSeek-R1-0528-Qwen3-8B** yang mencetak akurasi 86,0% pada tolok ukur AIME 2024 serta keluarga model tanpa sensor dari **huihui-ai**—seperti Huihui-Qwen3.8-27B-abliterated-GGUF dan Huihui-Qwen3.6-35B-A3B-abliterated yang mengablasi lapisan tengah-akhir secara selektif tanpa merusak lapisan awal maupun modul visual—memungkinkan mesin inferensi lokal (llama.cpp, vLLM, Ollama, atau Edge0 pada RAM 2,5 GB) mengambil alih lebih dari 50% beban kerja harian melalui pemilahan otomatis RouteLLM pada ambang batas \tau = 0,11593. Penegakan wajib terhadap format tensor nir-eksekusi (.safetensors dan .gguf) yang dikombinasikan dengan pemindaian statis **protectai/modelscan** serta tata kelola runtime **Microsoft Agent Governance Toolkit** menjamin bahwa kebebasan eksplorasi tanpa sensor tersebut sepenuhnya terlindung dari ancaman penyusupan malware serialisasi pickle maupun eksekusi perintah destruktif.
Sebagai fondasi keberlanjutan jangka panjang, integrasi antara ketahanan akuisisi data web dan siklus ekonomi mandiri (*self-sustaining compute loop*) memastikan agregator mampu mendanai ekspansi perangkat kerasnya sendiri secara otonom. Menggantikan perayap web tunggal dengan rantai pengalihan **spider-rs/spider** \rightarrow **D4Vinci/Scrapling** (scrapling-rs) \rightarrow **Crawl4AI** (terisolasi secara internal) yang disuplai oleh lebih dari 15 umpan proksi multi-CDN (TheSpeedX, proxifly, monosans, jetkai, roosterkid, jhao104/proxy_pool) menghilangkan risiko kegagalan ekstraksi data akibat perubahan struktur DOM maupun proteksi Cloudflare Turnstile. Di hilir, perpaduan antara gerbang pembayaran tanpa kartu Visa (Pakasir \rightarrow Tripay \rightarrow Duitku \rightarrow @CryptoBot USDT) untuk membiayai pengisian saldo API grosir berbasis kripto (Novita AI, RunPod, Vast.ai, PiAPI) dan partisipasi perangkat keras menganggur pada jaringan DePIN (**Bittensor Subnet 27**, **Nosana**, **IO.net**, dan **Akash Network**) menutup siklus operasional sehingga seluruh ekosistem dapat tumbuh tanpa ketergantungan modal eksternal.

Karya yang dikutip

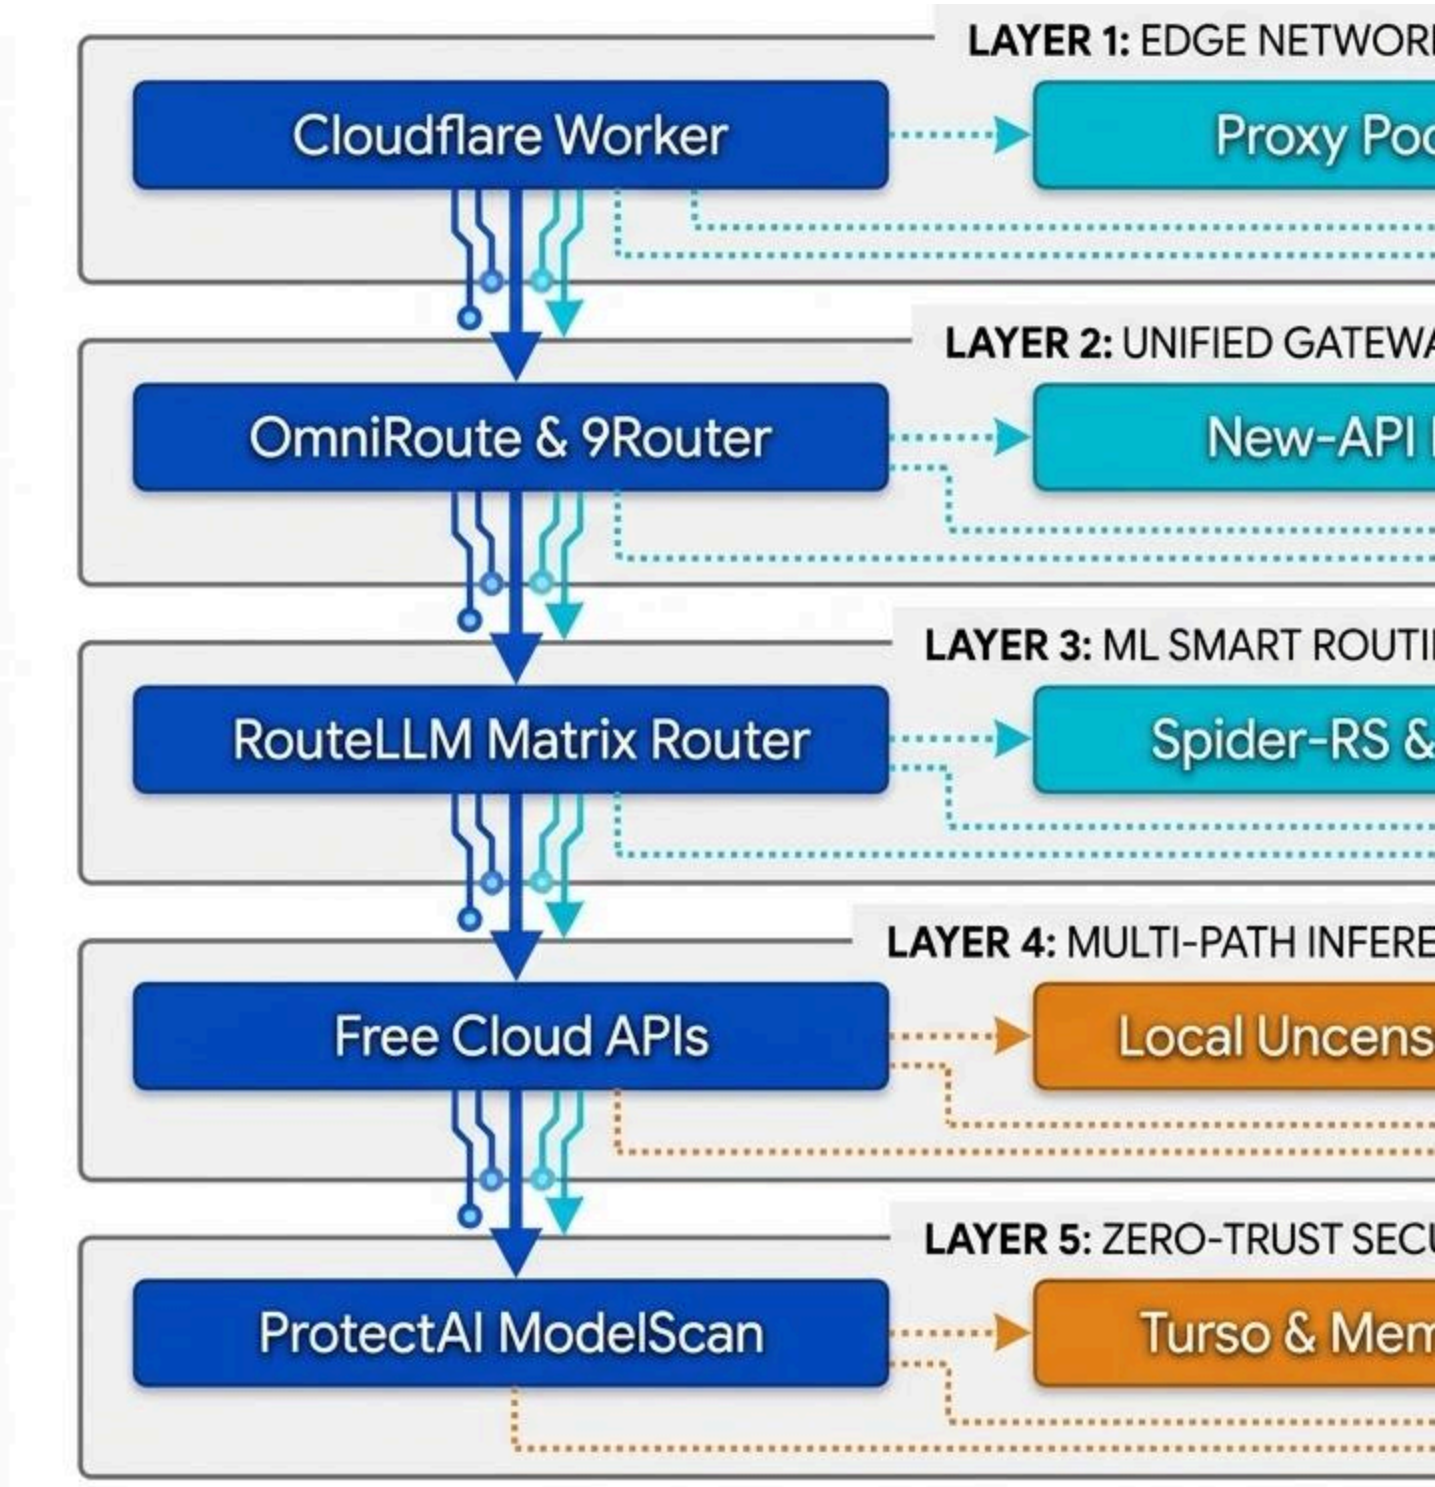
1. Free LLM APIs: No Credit Card, Verified Each Release, https://klymentiev.com/blog/free-llm-api 2. Free LLM API list. Permanent free tiers only. : r/better_claw - Reddit, https://www.reddit.com/r/better_claw/comments/1vef1nz/free_llm_api_list_permanent_free_tiers_only/ 3. Free LLM APIs Compared: Rate Limits, Models, and Real Costs (2026), https://openrouter.ai/blog/tutorials/free-llm-apis-compared/ 4. Proxy-Grabber-and-Checker/Sources.txt at main - GitHub, https://github.com/saschazesiger/Proxy-Grabber-and-Checker/blob/main/Sources.txt 5. getproxy/start.sh at master - GitHub, https://github.com/noctiro/getproxy/blob/master/start.sh 6. huihui-ai/Huihui-Qwen3.8-27B-abliterated - Hugging Face, https://huggingface.co/huihui-ai/Huihui-Qwen3.8-27B-abliterated 7. gpt-oss-abliterated - a huihui-ai Collection - Hugging Face, https://huggingface.co/collections/huihui-ai/gpt-oss-abliterated 8. spider-rs/spider: Foundational low latency web data collecting in Rust, https://github.com/spider-rs/spider 9. huihui-ai/Huihui-Qwen3.8-Flash-Next-abliterated-v2-GGUF, https://huggingface.co/huihui-ai/Huihui-Qwen3.8-Flash-Next-abliterated-v2-GGUF 10. pchide/Proxy-List-Live - GitHub, https://github.com/pchide/Proxy-List-Live 11.

Zaeem20/FREE_PROXIES_LIST — GitHub trending stats & insights, https://trendshift.io/repositories/118339 12. Auto-Proxy-Fetcher/fetch_proxies.py at main - GitHub, https://github.com/VolkanSah/Auto-Proxy-Fetcher/blob/main/fetch_proxies.py 13. GitHub - WangYihang/Proxy-Verifier: A set of tools designed to, https://github.com/WangYihang/Proxy-Verifier 14. What Is huihui-ai (huihui AI)? Abliterated Models Guide, https://deepentresearch.com/en/journal/huihui-ai 15. Overview · cooper1637/SageAttention · GitHub, https://github.com/cooper1637/SageAttention/security 16. ali-vilab/TeaCache: Timestep Embedding Tells: It's Time to Cache, https://github.com/ali-vilab/TeaCache 17. InstantID: Zero-shot Identity-Preserving Generation in Seconds, https://github.com/instantx-research/instantid 18. rhasspy/piper: A fast, local neural text to speech system - GitHub, https://github.com/rhasspy/piper 19. Issue #2762 · k2-fsa/sherpa-onnx - tts模型推荐 - GitHub, https://github.com/k2-fsa/sherpa-onnx/issues/2762 20. Releases · rhasspy/piper - GitHub, https://github.com/rhasspy/piper/releases 21. GitHub - Portkey-AI/gateway, https://github.com/portkey-ai/gateway 22. D4Vinci/Scrapling: 🕷️ A Web Scraping framework that ... - GitHub, https://github.com/d4vinci/Scrapling 23. GitHub - chrisabruce/scrapling-rs: Adaptive web scraping, built in, https://github.com/chrisabruce/scrapling-rs 24. Scrapling: Adaptive Python web scraping library that handles, https://www.scrapingbee.com/blog/scrapling-adaptive-python-web-scraping/ 25. Scrapling: Python Web Scraping Framework, https://scrapling.readthedocs.io/en/latest/index.html 26. Spider: a streaming Rust crawler that starts with HTTP - Hysen Labs, https://hysenlabs.com/projects/spider-rs-spider 27. ComfyUI-TeaCache - ComfyICU, https://comfy.icu/extension/welltop-cn__ComfyUI-TeaCache 28. TeaCache/TeaCache4Wan2.1/README.md at main · ali ... - GitHub, https://github.com/ali-vilab/TeaCache/blob/main/TeaCache4Wan2.1/README.md 29. Akash Network - GitHub, https://github.com/akash-network 30. GitHub - akash-network/node: Source code for Akash node, a, https://github.com/akash-network/node 31. Node Architecture - Your Guide to Decentralized Cloud, https://akash.network/docs/node-operators/architecture/ 32. Releases · akash-network/node - GitHub, https://github.com/ovrclk/akash/releases 33. huihui-ai/Huihui-Qwen3.6-35B-A3B-abliterated - Hugging Face, https://huggingface.co/huihui-ai/Huihui-Qwen3.6-35B-A3B-abliterated

Arsitektur Induk Agregator AI Otonom Multi-Jalur: Konsolidasi Ekosistem Sumber Daya Terbuka, Orkestrasi Failover Deterministik, dan Direktori Komputasi Tanpa Biaya

Paradigma Redundansi Multi-Jalur dan Dinamika Kuota Komputasi 2026

Ketergantungan pada satu jalur eksekusi tunggal (*single-path dependency*) dalam pengembangan sistem kecerdasan buatan (AI) otonom merupakan penyebab utama kegagalan operasional di lingkungan produksi. Bukti empiris sepanjang pertengahan hingga akhir tahun 2026 memperlihatkan betapa cepatnya penyedia layanan komputasi mengubah kebijakan kuota gratis mereka secara sepihak akibat lonjakan beban inferensi global. Pada 16 Juli 2026, Cerebras menghentikan penawaran *free-tier* permanen tanpa kartu kredit (1 juta token/hari) untuk pendaftar baru dan menggantinya dengan kredit uji coba senilai $5 selama 30 hari yang mewajibkan verifikasi kartu pembayaran. Hanya berselang dua minggu, pada 30 Juli 2026, layanan GitHub Models resmi dipensiunkan beserta seluruh titik akhir API, taman bermain (*playground*), dan fitur *Bring-Your-Own-Key* (BYOK)-nya. Selanjutnya, pada 16 Agustus 2026, Groq menghapus model Llama 3.3 70B dan Llama 3.1 8B dari paket gratis serta pengembangnya, sementara SambaNova menghentikan pemberian kredit gratis bagi akun baru pada bulan yang sama, dan OpenRouter menghapus sejumlah titik akhir berlabel :free yang sebelumnya bersifat statis termasuk varian gratis DeepSeek dan Mistral lama.
Fenomena penyusutan kuota hulu ini membuktikan bahwa agen pemrograman AI tidak boleh menulis kode yang mengunci satu titik akhir (*hardcoded endpoint*), satu daftar proksi, atau satu mesin inferensi tunggal. Arsitektur agregator AI yang tangguh menuntut penerapan **Redundansi Multi-Jalur Deterministik (*N+M Rolling Failover Architecture*)**, di mana setiap fungsi kritis—mulai dari rotasi alamat IP, perayapan web (*web scraping*), inferensi bahasa besar (LLM), sintesis multimodal (video, gambar, suara, musik), hingga basis data memori dan gerbang pembayaran—memiliki rantai pengalihan otomatis berlapis sebelum batas kuota (*rate limit* HTTP 429) atau kegagalan jaringan (HTTP 5xx) menghentikan eksekusi.



Melalui arsitektur lima lapis tersebut, sistem pemrograman AI tidak lagi memperlakukan kegagalan API sebagai kondisi penghentian program (*fatal exception*), melainkan sebagai sinyal transisi status (*state transition signal*) yang memicu pergeseran rute secara deterministik. Apabila umpan proksi dari satu repositori GitHub mengalami gangguan atau pemblokiran DNS, modul penarik secara otomatis beralih ke cermin jaringan distribusi konten (CDN) jsDelivr dan

Fastly atau memanen dari belasan repositori independen lainnya. Apabila kuota harian Gemini atau Groq habis, *smart router* berbasis faktorisasi matriks dan *semantic cache* langsung mengalihkan beban kerja ke kuota bulanan Mistral Experiment Tier (1 miliar token/bulan), titik akhir dinamis openrouter/free, 91 model gratis di NVIDIA NIM, atau mengeksekusi model tanpa sensor (*abliterated*) secara lokal melalui llama.cpp dan vLLM dengan biaya operasional nol.

Klasifikasi Induk Terpadu Seluruh Tautan Sumber Daya dan Ekspansi Alternatif

Untuk memenuhi tuntutan rekayasa sistem yang membutuhkan satu dokumen induk tunggal yang mengonsolidasikan seluruh isi dari ketiga berkas sumber (LINK SUMBER.pdf, Sumber Daya Utama.pdf, dan Link_daftar_vps server.txt) sekaligus memperluasnya dengan tautan alternatif yang lebih unggul dari hasil riset terbaru, seluruh sumber daya diklasifikasikan secara ketat ke dalam tiga kelompok aksesibilitas utama. Struktur di bawah ini mempertahankan pengelompokan asli (**Kelompok 1: 1A–1E**, **Kelompok 2: 2A–2C**, dan **Kelompok 3: 3A–3B**), mencantumkan seluruh 159 tautan dari berkas pertama serta 40 tautan dari berkas cetak biru VPS/Omnichannel, lalu menyandingkannya secara langsung dengan repositori, umpan mentah (*raw feeds*), dan titik akhir alternatif yang memiliki performa lebih tinggi sebagai jalur *rolling failover* otomatis.

Kelompok 1: Tanpa Perlu Mendaftar (Otomatis Terkoneksi, Direct Clone, Direct Pull, dan Umpan Publik)

Seluruh sumber daya di dalam Kelompok 1—yang juga mencakup seluruh komponen perangkat lunak dari Kategori 3 pada cetak biru VPS—tidak memerlukan pembuatan akun, autentikasi OAuth, maupun kartu pembayaran. Agen AI dapat langsung mengintegrasikan titik akhir ini ke dalam skrip otomatis (curl atau httpx), menarik bobot model melalui antarmuka baris perintah (llama.cpp, Ollama, vLLM, Docker Model Runner), atau melakukan git clone secara instan ke lingkungan eksekusi lokal.

1A. Umpan Proksi Publik, API Rotasi Tanpa Kunci & Jaringan Otomatis (Langsung Terkoneksi)

Pada lapisan rotasi IP dan titik akhir publik nir-autentikasi, ketergantungan tunggal pada monosans/proxy-list memiliki risiko kejenuhan alamat IP akibat tingginya pengguna konkuren yang memanen dari satu daftar yang sama. Penelusuran mendalam terhadap ekosistem pemanen proksi terbuka mengungkap repositori dengan frekuensi pembaruan jauh lebih cepat (setiap 1 hingga 10 menit), volume kolam IP yang jauh lebih masif (hingga 5.610+ proksi aktif per pemindaian pada TheSpeedX/PROXY-List dan 6.900+ bintang pada proxifly/free-proxy-list), serta jalur akses melalui jaringan distribusi konten (cdn.jsdelivr.net dan fastly.jsdelivr.net) untuk menembus pembatasan laju permintaan (*rate-limit*) atau pemblokiran ISP terhadap domain raw.githubusercontent.com. Selain itu, penyediaan titik akhir REST API nir-kunci seperti ProxyScrape v2 dan GeoNode API beserta perkakas verifikasi berbasis Go (WangYihang/Proxy-Verifier) menjamin bahwa agen tetap dapat memperoleh IP bersih yang teruji bebas *cache* meskipun seluruh repositori GitHub mengalami gangguan layanan.

No	Nama Sumber & Fungsi Utama	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Bukti Teknis, Kapasitas & Peran Failover
1A.1	**Monosans Proxy List** (Repositori Induk & Raw SOCKS5/HTTP/JSON)	Repo: https://github.com/monosans/proxy-list SOCKS5: https://raw.githubusercontent.com/monosans/proxy-list/main/proxies/socks5.txt HTTP: https://raw.githubusercontent.com/monosans/proxy-list/main/proxies/http.txt JSON ASN: https://raw.githubusercontent.com/monosans/proxy-list/main/proxies.json	CDN HTTP: https://cdn.jsdelivr.net/gh/monosans/proxy-list@main/proxies/http.txt CDN SOCKS5: https://cdn.jsdelivr.net/gh/monosans/proxy-list@main/proxies/socks5.txt CDN SOCKS4: https://cdn.jsdelivr.net/gh/monosans/proxy-list@main/proxies/socks4.txt Geo Anon: https://raw.githubusercontent.com/monosans/proxy-list/main/proxies_geolocation_anonymous/socks4.txt	Diperbarui setiap jam tanpa kunci API, diurutkan dari respons tercepat, dilengkapi metadata exit_ip, ASN, dan geolokasi MaxMind GeoLite2. Jalur CDN jsDelivr menjamin unduhan tetap berhasil meski GitHub Raw diblokir ISP.
1A.2	**TheSpeedX & Proxifly Mega Proxy Pools** (Alternatif Superior Volume & Kecepatan)	*(Diperluas dari umpan dasar 1A.1)*	TheSpeedX Repo: https://github.com/TheSpeedX/PROXY-List Raw HTTP: https://raw.githubusercontent.com/TheSpeedX/PROXY-List/master/http.txt Raw SOCKS4: https://raw.githubusercontent.com/TheSpeedX/PROXY-List/master/socks4.txt Raw SOCKS5: https://raw.githubusercontent.com/TheSpeedX/PROXY-List/master/socks5.txt Fastly CDN: https://fastly.jsdelivr.net/gh/TheSpeed	TheSpeedX/PROXY-List (5,9 ribu bintang) menyediakan 5.610 proksi aktif terverifikasi (dibandingkan ~408 pada monosans). proxifly/free-proxy-list (6,9 ribu bintang) memperbarui daftar HTTP, SOCKS4, dan SOCKS5 setiap 5 menit dari 100+ negara.

No	Nama Sumber & Fungsi Utama	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Bukti Teknis, Kapasitas & Peran Failover
			X/PROXY-List@master/socks5.txt SOCKS-List: https://raw.githubusercontent.com/TheSpeedX/SOCKS-List/master/socks5.txt Proxifly (Update 5 Menit): https://github.com/proxifly/free-proxy-list	
1A.3	**Multi-Repo Raw Proxy Streams** (Jalur Rolling 15+ Sumber Independen)	*(Cadangan berlapis untuk monosans)*	Jetkai HTTP: https://raw.githubusercontent.com/jetkai/proxy-list/main/online-proxies/txt/proxies-http.txt Jetkai HTTPS: https://raw.githubusercontent.com/jetkai/proxy-list/main/online-proxies/txt/proxies-https.txt Jetkai SOCKS5 (Fastly): https://fastly.jsdelivr.net/gh/jetkai/proxy-list@main/online-proxies/txt/proxies-socks5.txt Roosterkid HTTPS: https://raw.githubusercontent.com/roosterkid/openproxylist/main/HTTPS_RAW.txt Roosterkid SOCKS5: https://raw.githubusercontent.com/roosterkid/openproxy	Menggabungkan lebih dari 15 umpan mentah independen yang diperbarui setiap 1 hingga 60 menit dalam format TXT, JSON, CSV, dan YAML (termasuk konfigurasi V2Ray/XRay, WireGuard, dan MTProto Telegram pada gfpcom dan hookzof).

No	Nama Sumber & Fungsi Utama	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Bukti Teknis, Kapasitas & Peran Failover
			list/main/SOCKS5_RAW.txt Clarketm Raw: https://raw.githubusercontent.com/clarketm/proxy-list/master/proxy-list-raw.txt Hookzof SOCKS5: https://raw.githubusercontent.com/hookzof/socks5_list/master/proxy.txt Hookzof JSON/MTProto: https://raw.githubusercontent.com/hookzof/socks5_list/master/tg/socks.json & mtproto.json BlackSnowDot (Update 1 Menit): https://raw.githubusercontent.com/BlackSnowDot/proxylist-update-every-minute/main/http.txt & https.txt & socks.txt ShiftyTR: https://raw.githubusercontent.com/ShiftyTR/Proxy-List/master/http.txt & https.txt & socks5.txt UptimerBot: https://raw.githubusercontent.com/UptimerBot/proxy-list/main/proxies/http.txt & socks5.txt RX4096: https://raw.githubu	

No	Nama Sumber & Fungsi Utama	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Bukti Teknis, Kapasitas & Peran Failover
			sercontent.com/RX4096/proxy-list/main/online/http.txt & socks5.txt mmpx12: https://raw.githubusercontent.com/mmpx12/proxy-list/master/http.txt & socks5.txt manuGMG: https://raw.githubusercontent.com/manuGMG/proxy-365/main/SOCKS5.txt Vakhov / gfpcom / zloi-user / fate0: https://github.com/vakhov/fresh-proxy-list, https://github.com/gfpcom/free-proxy-list, https://github.com/zloi-user/hideip.me, https://raw.githubusercontent.com/fate0/proxylist/master/proxy.list	
1A.4	**Zero-Auth Public Proxy APIs** (REST Endpoints Tanpa Registrasi)	*(Tambahan jalur non-GitHub)*	ProxyScrape v2 API: https://api.proxyscrape.com/v2/?request=displayproxies&protocol=socks5&timeout=10000&country=all GeoNode JSON API: https://proxylist.geonode.com/api/proxy-list?limit=500&p	Memberikan jalur pengalihan di luar infrastruktur GitHub. proxyscrape.com menyumbang 1.092+ proksi terverifikasi per siklus, sementara geonode.com menyajikan hingga 500 proksi per halaman yang

No	Nama Sumber & Fungsi Utama	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Bukti Teknis, Kapasitas & Peran Failover
			age=1&sort_by=lastChecked&sort_type=desc&protocols=http%2Chttps Proxy-List Download API: https://www.proxy-list.download/api/v1/get?type=http (mendukung https, socks4, socks5) ProxyScan API: https://www.proxyscan.io/download?type=http OpenProxyList API: https://api.openproxylist.xyz/http.txt & socks4.txt	diurutkan berdasarkan lastChecked terbaru.
1A.5	**Proxy Pool Auto-Harvester & Verifier Engines** (Daemon Lokal)	Utama: https://github.com/jhao104/proxy_pool (http://127.0.0.1:5010/get/) Mirror/Fork: https://github.com/ccfleaf/jhao104-proxy_pool	Go Proxy-Verifier: https://github.com/WangYihang/Proxy-Verifier (sources.yaml: https://raw.githubusercontent.com/WangYihang/Proxy-Verifier/main/sources.yaml) Live Scanner (Update 2-3 Menit): https://github.com/pchide/Proxy-List-Live Auto-Proxy-Fetcher: https://github.com/VolkanSah/Auto-Proxy-Fetcher Fast Scraper (10k/10s): https://github.com/GokuCodeZ/Proxy	jhao104/proxy_pool (23,8 ribu bintang) memvalidasi proksi via ip.sb ke Redis lokal. Sebagai alternatif berkinerja tinggi, WangYihang/Proxy-Verifier berbasis Go memisahkan 4 modul (downloader, echo-server, verifier dengan validasi hash anti-cache, dan exporter).