No	Nama Sumber & Fungsi Utama	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Bukti Teknis, Kapasitas & Peran Failover
			-Scraper Shell Harvester: https://github.com/noctiro/getproxy Grabber & Checker: https://github.com/saschazesiger/Proxy-Grabber-and-Checker	
1A.6	**Pollinations AI** (Zero-Auth Multimodal Endpoint & Sandbox)	Repo: https://github.com/pollinations/pollinations Web/Endpoint: https://pollinations.ai/	Digunakan sebagai *Fallback Mode [1]* untuk generasi gambar, teks, dan audio HTTP langsung ketika seluruh kunci API komersial atau gratis sedang habis kuota.	Merespons permintaan HTTP secara instan untuk sintesis teks, gambar, dan suara tanpa pembuatan akun maupun kunci API.

1B. Model LLM Uncensored / Abliterated & Penalaran SOTA (Direct Pull tanpa Login)

Seluruh bobot model pada sub-kategori 1B didistribusikan dalam format tensor nir-eksekusi yang aman dari penyusupan malware (.safetensors dan .gguf) serta dapat ditarik tanpa akun menggunakan perintah llama serve -hf <repo>, ollama run hf.co/<repo>, atau docker model run hf.co/<repo>. Sebagai peningkatan substansial di atas model *abliterated* generasi awal (bartowski dan mradermacher), riset mengidentifikasi ekosistem **huihui-ai** di Hugging Face yang telah melampaui 2,2 juta unduhan pada Oktober 2026. Keunggulan utama huihui-ai adalah kecepatan adaptasinya terhadap rilis model terbaru (mencakup keluarga Qwen3.8, Qwen3.6, Gemma-4, GLM-5.3, DeepSeek-V4, dan GPT-OSS) serta penerapan *abliteration* selektif pada lapisan tengah-akhir—misalnya hanya mengablasi lapisan 18 hingga 51 pada Huihui-Qwen3.8-27B-abliterated sambil mempertahankan 15 lapisan pertama, modul *Multi-Token Prediction* (MTP), dan proyeksi visual tetap utuh—sehingga menghilangkan mekanisme penolakan (*refusal*) tanpa mengorbankan kecerdasan penalaran maupun kapabilitas multimodal (*Vision-Language*).

No	Nama Sumber & Keluarga Model	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis, Format & Peran Failover
1B.1	**Keluarga Qwen3 & Qwen3.8**	Qwen3-8B (Bartowski):	Creator Hub: https://huggingface	Kuantisasi GGUF dari 2-bit (IQ2_M

No	Nama Sumber & Keluarga Model	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis, Format & Peran Failover
	Abliterated (Kompak & Menengah)	https://huggingface.co/bartowski/mlabonne_Qwen3-8B-abliterated-GGUF Qwen3-14B (Bartowski): https://huggingface.co/bartowski/mlabonne_Qwen3-14B-abliterated-GGUF	.co/huihui-ai Qwen3.8-27B Safetensors: https://huggingface.co/huihui-ai/Huihui-Qwen3.8-27B-abliterated Qwen3.8-27B GGUF: https://huggingface.co/huihui-ai/Huihui-Qwen3.8-27B-abliterated-GGUF Qwen3.8 Flash Next v2 GGUF: https://huggingface.co/huihui-ai/Huihui-Qwen3.8-Flash-Next-abliterated-v2-GGUF Qwen3.6-27B / Qwen3.5-27B / 9B / 4B: https://huggingface.co/huihui-ai/Huihui-Qwen3.6-27B-abliterated & Huihui-Qwen3.5-27B-abliterated	3,05 GB) hingga 8-bit. Huihui-Qwen3.8-27B-abliterated mendukung input *Image-Text-to-Text* dan dapat dipanggil langsung via ollama run huihui_ai/Qwen3.8-abliterated atau llama serve -hf huihui-ai/Huihui-Qwen3.8-Flash-Next-abliterated-v2-GGUF:UD-Q4_K_XL.
1B.2	**Model MoE & Frontier Raksasa Abliterated** (30B hingga 671B)	Llama-3-70B Abliterated: https://huggingface.co/bartowski/llama-3-70B-Instruct-abliterated-GGUF Qwen3-30B-A3B MoE: https://huggingface.co/mradermacher/Qwen3-30B-A3B-abliterated-GGUF DeepSeek-V3 Abliterated:	Qwen3.6-35B-A3B MoE: https://huggingface.co/huihui-ai/Huihui-Qwen3.6-35B-A3B-abliterated (ollama run huihui_ai/qwen3.6-abliterated:35b) Ollama MoE Hub: https://ollama.com/huihui_ai/huihui-moe-abliterated GPT-OSS	Arsitektur *Mixture-of-Experts* (30B–35B total parameter dengan hanya 3B parameter aktif per token) memberikan kecepatan inferensi setara model kecil dengan kecerdasan model besar. Koleksi

No	Nama Sumber & Keluarga Model	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis, Format & Peran Failover
		https://huggingface.co/mradermacher/DeepSeek-V3-abliterated-GGUF	Collection: https://huggingface.co/collections/huihui-ai/gpt-oss-abliterated GPT-OSS 20B BF16 / v2 / mxfp4: https://huggingface.co/huihui-ai/Huihui-gpt-oss-20b-BF16-abliterated & Huihui-gpt-oss-20b-BF16-abliterated-v2 & Huihui-gpt-oss-20b-mxfp4-abliterated-v2 GLM-4.5-Air GGUF: https://huggingface.co/huihui-ai/Huihui-GLM-4.5-Air-abliterated-GGUF	huihui-ai juga mencakup DeepSeek-671B-abliterated, DeepSeek-V4-abliterated, dan GLM-5.3-abliterated.
1B.3	**Model Spesialis Koding & Keamanan Siber Abliterated**	*(Ekspansi dari 1B.1 & 1B.2)*	Gemma-4 12B IT: https://huggingface.co/huihui-ai/Huihui-gemma-4-12B-it-abliterated Gemma-4 12B Coder: https://huggingface.co/huihui-ai/Huihui-gemma-4-12B-coder-fable5-composer2.5-v1-abliterated Gemma-4 26B-A4B MoE: https://huggingface.co/huihui-ai/Huihui-gemma-4-26B-A4B-it-abliterated Qwen3-Coder-Next: https://huggingface	Dirancang khusus untuk agen *red-teaming*, audit keamanan siber ofensif (CyberStrike-OffSec-35B), dan rekayasa perangkat lunak otonom (Qwen3-Coder-Next & Gemma-4-12B-coder) tanpa pemblokiran heuristik.

No	Nama Sumber & Keluarga Model	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis, Format & Peran Failover
			.co/huihui-ai/Huihui-Qwen3-Coder-Next-abliterated CyberStrike-OffSec-35B: https://huggingface.co/huihui-ai/Huihui-CyberStrike-OffSec-35B-abliterated Qwythos-9B-1M Context: https://huggingface.co/huihui-ai/Huihui-Qwythos-9B-Claude-Mythos-5-1M-abliterated-GGUF	
1B.4	**Keluarga Penalaran SOTA DeepSeek-R1 & V3**	R1-0528-Qwen3-8B: https://huggingface.co/deepseek-ai/DeepSeek-R1-0528-Qwen3-8B R1 GGUF (Unsloth): https://huggingface.co/unsloth/DeepSeek-R1-GGUF R1-0528 (684B Full): https://huggingface.co/deepseek-ai/DeepSeek-R1-0528 R1-Distill-Qwen-32B: https://huggingface.co/deepseek-ai/DeepSeek-R1-Distill-Qwen-32B V3-Base: https://huggingface.co/deepseek-ai/DeepSeek-V3-Base	Huihui Qwen3.5-4B-Claude-4.6-Opus Reasoning Distill: https://huggingface.co/huihui-ai/Huihui-Qwen3.5-4B-Claude-4.6-Opus-abliterated Llama-3.2-3B-Instruct Abliterated: https://huggingface.co/huihui-ai/Llama-3.2-3B-Instruct-abliterated	DeepSeek-R1-0528-Qwen3-8B mencapai akurasi 86,0% pada AIME 2024, melampaui o3-mini (79,6%) dan Gemini-2.5-Flash-Thinking (82,3%), sehingga menjadi *worker* penalaran lokal utama.
1B.5	**Katalog Uncensored**	Katalog: https://huggingface	Digunakan sebagai jalur	Berbeda dengan *abliteration* yang

No	Nama Sumber & Keluarga Model	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis, Format & Peran Failover
	Berbasis Dataset Dolphin (Retraining-Based)	.co/models?dataset=dataset:cognitivecomputations/dolphin Dolphin-2.9-Llama3-8B: https://huggingface.co/cognitivecomputations/dolphin-2.9-llama3-8b Dolphin-2.7-Mixtral-8x7B-4bit (Apple MLX): https://huggingface.co/mlx-community/dolphin-2.7-mixtral-8x7b-4bit	alternatif apabila tugas agen membutuhkan gaya percakapan yang dilatih ulang secara penuh pada dataset tanpa filter (*fine-tuned*) dibandingkan penyuntingan bobot (*abliteration*).	memodifikasi matriks bobot secara bedah vektor, keluarga Dolphin melatih ulang model pada korpus instruksi bersih tanpa penolakan.
1B.6	**Model Dasar Qwen, Bobot Router & Dataset Kalibrasi Abliteration**	Qwen3.5-4B: https://huggingface.co/Qwen/Qwen3.5-4B Qwen2.5-1.5B-Instruct: https://huggingface.co/Qwen/Qwen2.5-1.5B-Instruct Qwen3-8B-Base: https://huggingface.co/Qwen/Qwen3-8B-Base Qwen3-235B-A22B: https://huggingface.co/Qwen/Qwen3-235B-A22B RouteLLM Weights: https://huggingface.co/routellm/mf_gpt4_augmented Semantic-Harmless: https://huggingface	Qwen3.8-27B Base: https://huggingface.co/Qwen/Qwen3.8-27B Qwen3.6-35B-A3B Base: https://huggingface.co/Qwen/Qwen3.6-35B-A3B	Menyediakan model fondasi untuk eksperimen ablasi mandiri, bobot faktorisasi matriks untuk lm-sys/RouteLLM, serta pasangan dataset kalibrasi semantik yang terbukti menekan derau (*noise*) ruang residual hingga D_{\text{KL}} = 0,0509.

No	Nama Sumber & Keluarga Model	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis, Format & Peran Failover
		.co/datasets/heretic-org/Semantic-Harmless Semantic-Harmful: https://huggingface.co/datasets/heretic-org/Semantic-Harmful Multilingual: https://huggingface.co/datasets/heretic-org/Multilingual-Harmless-Harmful		

1C. Model & Engine Multimodal SOTA (Video, Gambar, Suara, Musik, Visi - Tanpa Login)

Integrasi seluruh tautan dari sub-kategori 1C pada LINK SUMBER.pdf dan komponen multimodal dari Kategori 3 pada Link_daftar_vps server.txt diperkuat dengan repositori resmi **ali-vilab/TeaCache** (CVPR 2025 Highlight), **thu-ml/SageAttention** (hulu resmi dari fork cooper1637), **instantX-research/InstantID** (pendamping PuLID), serta mesin TTS lokal berkecepatan ekstrem **OHF-Voice/piper1-gpl** (penerus resmi rhasspy/piper yang diarsipkan pada Oktober 2025) dan **k2-fsa/sherpa-onnx**. Kombinasi ini memungkinkan agen melakukan degradasi anggun (*graceful degradation*) dari sintesis video/suara berkapasitas besar pada GPU menuju model ultra-ringan yang tetap berjalan mulus di atas CPU atau perangkat tepi (*edge*).

No	Nama Sumber & Modalitas	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis, Kebutuhan VRAM & Peran Failover
1C.1	**Koleksi Lengkap Wan2.1 & Wan2.2** (Generasi & Penyuntingan Video SOTA)	Koleksi: https://huggingface.co/collections/Wan-AI/wan21 T2V-1.3B: https://huggingface.co/Wan-AI/Wan2.1-T2V-1.3B/tree/main T2V-14B: https://huggingface.co/Wan-AI/Wan2.1-T2V-14B I2V-14B-720P VAE: https://huggingface	Wan-AI Org & Diffusers Collections (Wan2.2-diffusers, Wan2.1-diffusers): https://huggingface.co/Wan-AI/collections Official HF Space (ZeroGPU Fallback): https://huggingface.co/spaces/Wan-AI/Wan2.1 TeaCache4Wan2.1 Script:	Mencakup T2V, I2V, *First-Last-Frame-to-Video* (FLF2V), dan *Video All-in-one Creation & Editing* (VACE) berlisensi Apache-2.0. Wan2.1 merupakan model video pertama yang mampu merender teks visual bahasa

No	Nama Sumber & Modalitas	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis, Kebutuhan VRAM & Peran Failover
		.co/Wan-AI/Wan2.1-I2V-14B-720P/blob/main/Wan2.1_VAE.pth I2V-14B-480P: https://huggingface.co/Wan-AI/Wan2.1-I2V-14B-480P FLF2V-14B-720P: https://huggingface.co/Wan-AI/Wan2.1-FLF2V-14B-720P VACE-14B: https://huggingface.co/Wan-AI/Wan2.1-VACE-14B VACE-1.3B: https://huggingface.co/Wan-AI/Wan2.1-VACE-1.3B Wan2.2-TI2V-5B MoE: https://huggingface.co/Wan-AI/Wan2.2-TI2V-5B	https://github.com/ali-vilab/TeaCache/blob/main/TeaCache4Wan2.1/README.md	Inggris dan Mandarin secara akurat.
1C.2	**Tencent HunyuanVideo Suite** (T2V, I2V, Avatar & Foley)	HunyuanVideo-1.5 (Distilasi 4–12 Langkah): https://github.com/Tencent-Hunyuan/HunyuanVideo-1.5 Lisensi 1.5: https://github.com/Tencent-Hunyuan/HunyuanVideo-1.5/blob/main/LICENSE HunyuanVideo Base: https://github.com/Tencent-Hunyuan/HunyuanVideo HunyuanVideo-I2V:	Digunakan secara berpasangan: HunyuanVideo-Foley sebagai generator efek suara utama dan hkchengrex/MMAudio (157 juta parameter) sebagai *fallback* ringan untuk sinkronisasi Video-to-Audio (V2A).	HunyuanVideo-1.5 memangkas waktu render sebesar 75% (<75 detik pada RTX 4090) melalui distilasi langkah dan sgl-kernel==0.3.18. HunyuanVideo-Avatar berjalan hanya dalam 10 GB VRAM menggunakan integrasi Wan2GP dan TeaCache.

No	Nama Sumber & Modalitas	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis, Kebutuhan VRAM & Peran Failover
		https://github.com/Tencent-Hunyuan/HunyuanVideo-I2V HunyuanVideo-Avatar (10 GB VRAM): https://github.com/tencent-hunyuan/hunyuanvideo-avatar HunyuanVideo-Foley: https://github.com/Tencent-Hunyuan/HunyuanVideo-Foley MMAudio (157M V2A Foley dari Sumber 3): https://github.com/hkchengrex/MMAudio		
1C.3	**Lightricks LTX-Video & LTX-2** (Video + Audio Tersinkronisasi 8 GB VRAM)	Repo Kode: https://github.com/Lightricks/ltx-video Bobot HF: https://huggingface.co/Lightricks/LTX-Video	TeaCache4LTX-Video: https://github.com/ali-vilab/TeaCache/blob/main/TeaCache4LTX-Video/README.md	Varian terkuantisasi 8-bit LTX-VideoQ8 merender video 720 \times 480 \times 121 frame dalam <1 menit pada RTX 4060 (8 GB VRAM), mendukung *long-shot* 60 detik dan kontrol IC-LoRA.
1C.4	**Akselerator Atensi & Caching Difusi** (SageAttention, Flex-Block-Attn, TeaCache)	Flex-Block-Attn: https://github.com/Tencent-Hunyuan/flex-block-attn SageAttention (Fork): https://github.com/cooper1637/SageAttention	TeaCache Official Repo: https://github.com/ali-vilab/TeaCache (Mirror: https://github.com/LiewFeng/TeaCache) ComfyUI-TeaCach	thu-ml/SageAttention (ICLR/ICML/NeurIPS 2025) memberikan akselerasi atensi terkuantisasi 2–5x lipat dibanding FlashAttention

No	Nama Sumber & Modalitas	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis, Kebutuhan VRAM & Peran Failover
		SageAttention (Hulu Resmi dari Sumber 3): https://github.com/thu-ml/SageAttention	e (5 Custom Nodes): https://github.com/welltop-cn/ComfyUI-TeaCache TeaCache Sub-Modules: https://github.com/ali-vilab/TeaCache/blob/main/TeaCache4FLUX/README.md, TeaCache4HiDream-I1/README.md, TeaCache4Lumina-T2X/README.md	tanpa degradasi metrik. ali-vilab/TeaCache mempercepat difusi video, gambar, dan audio 1,5x–3x secara *training-free*.
1C.5	**Konsistensi Identitas Wajah & Gerbang Visi Pra-Inferensi**	PuLID Flux II (Pengunci Wajah Lintas 6 Klip Video dari Sumber 3): https://github.com/ToTheBeginning/PuLID InsightFace (Deteksi Usia Wajah >23 Tahun dari Sumber 3): https://github.com/deepinsight/insightface	InstantID (Resmi): https://github.com/instantX-research/InstantID & https://github.com/InstantID/InstantID InstantID Fork/Docs: https://github.com/MFaceTech/InstantID & https://github.com/InstantID/instantid.github.io	InsightFace bertindak sebagai gerbang keamanan visi pra-inferensi. Jika PuLID Flux II mengalami kegagalan konvergensi gaya pada wajah tertentu, pipeline gambar atau video otomatis beralih ke InstantID untuk preservasi identitas *zero-shot* dalam hitungan detik.
1C.6	**Mesin Suara (TTS) Ultra-Ringan CPU & Edge** (Kokoro-82M, Piper, Sherpa-ONNX)	Kokoro-82M v1.0: https://huggingface.co/hexgrad/Kokoro-82M Kokoro-82M v1.1-zh: https://huggingface.co/hexgrad/Kokor	Piper TTS (C++ ONNX Archive): https://github.com/rhasspy/piper & Releases: https://github.com/rhasspy/piper/releases Piper1-GPL	Kokoro-82M (Apache-2.0, StyleTTS 2 + iSTFTNet) berjalan sangat cepat di CPU dengan biaya setara Rp 1/naskah

No	Nama Sumber & Modalitas	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis, Kebutuhan VRAM & Peran Failover
		o-82M-v1.1-zh Skrip EN: https://huggingface.co/hexgrad/Kokoro-82M-v1.1-zh/blob/main/samples/make_en.py Skrip ZH: https://huggingface.co/hexgrad/Kokoro-82M-v1.1-zh/blob/main/samples/make_zh.py Misaki G2P: https://github.com/hexgrad/misaki	(Repositori Aktif Baru): https://github.com/OHF-Voice/piper1-gpl Sherpa-ONNX (Runtime TTS/ASR Lintas Platform): https://github.com/k2-fsa/sherpa-onnx	(<$0,06/jam audio 24 kHz). Sebagai *fallback* biner C++ murni tanpa ketergantungan PyTorch, sistem otomatis beralih ke OHF-Voice/piper1-gpl atau k2-fsa/sherpa-onnx.
1C.7	**Mesin TTS Emosi Multi-Karakter & Voice Cloning SOTA** (Fish Speech, CosyVoice, F5-TTS, ChatTTS)	Fish Speech (S2-Pro & Drama 3): https://github.com/fishaudio/fish-speech Rilis Fish Speech: https://github.com/fishaudio/fish-speech/releases Ref Arsitektur: https://github.com/fishaudio/fish-speech?ref=archy.net Fun-CosyVoice 3.0: https://github.com/QwenAudio/CosyVoice F5-TTS Weights: https://huggingface.co/SWivid/F5-TTS F5-TTS Edge Forum: https://huggingface.co/SWivid/F5-TTS/discussions Emilia	Rantai Failover Audio: Fish Speech Drama 3 (MoE 35B-A3B, 16 pembicara, 15.000+ tag emosi/menyanyi, RTF 0,195) \rightarrow Fun-CosyVoice 3.0 (streaming vLLM 0.11.x+ & gRPC) \rightarrow F5-TTS (*Flow Matching* non-autoregresif di .safetensors) \rightarrow ChatTTS \rightarrow Kokoro-82M.	Memberikan redundansi penuh dari kloning suara studio beremosi kompleks hingga sintesis dialogis cepat pada perangkat keras terbatas (F5-TTS mendukung papan komputasi NPU 6 TOPS FP16).

No	Nama Sumber & Modalitas	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis, Kebutuhan VRAM & Peran Failover
		Dataset: https://huggingface.co/datasets/amphion/Emilia-Dataset ChatTTS: https://huggingface.co/2Noise/ChatTTS		

1D. Agregator API, Smart Router, Semantic Cache, Abliteration Toolkit & Pemindai Malware (Open-Source Lokal)

Sub-kategori 1D menggabungkan seluruh 43 perkakas infrastruktur dari LINK SUMBER.pdf dengan Valkey/RedisVL, Langfuse, dan NVIDIA NeMo Guardrails dari Link_daftar_vps server.txt, serta menambahkan **Portkey-AI/gateway** (gerbang TypeScript ultra-cepat yang merutekan ke 1.600+ LLM dengan 50+ *guardrails* bawaan), **lemonade-server.ai**, dan direktori pemantau kuota API waktu nyata **cheahjs/free-llm-api-resources**. Keberadaan banyak gerbang mandiri ini memastikan bahwa apabila satu proses *gateway* mengalami gangguan (seperti masalah konversi antarmuka pada new-api#6352 atau kondisi balapan kuota TOCTOU pada one-api#2440), lalu lintas langsung dialihkan ke Portkey-AI/gateway atau BerriAI/litellm.

No	Nama Sumber & Kategori	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis & Peran dalam Rantai Failover
1D.1	**Agregator Titik Akhir Gratis & Konverter Klien**	OmniRoute (359 Penyedia, 150+ Gratis): https://github.com/diegosouzapw/OmniRoute FreeLLMAPI (34 Penyedia, 635 Endpoint): https://github.com/tashfeenahmed/freellmapi 9Router (Jembatan Koding Tanpa Batas): https://github.com/decolua/9router AIClient2API: https://github.com/justlovemaki/AIClient2API EchoBird	Live Free API Tracker: https://github.com/cheahjs/free-llm-api-resources Awesome Free Models: https://github.com/12britz/awesome-free-models Reputation Auditor: https://freeairouter.com/	OmniRoute (1.200+ model) dan freellmapi (7,4 miliar token/bulan) menyatukan ratusan kuota gratis di balik satu titik akhir /v1. 9router, AIClient2API, dan EchoBird mengonversi klien CLI (Claude Code, Codex, Kiro, Antigravity, Grok) menjadi API lokal.

No	Nama Sumber & Kategori	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis & Peran dalam Rantai Failover
		(Router Rust): https://github.com/edison7009/EchoBird		
1D.2	**Enterprise Self-Hosted API Gateways** (One-API, New-API, LiteLLM, Portkey)	One-API: https://github.com/songquanpeng/one-api One-API Releases: https://github.com/songquanpeng/one-api/releases One-API Charity Stations (公益站): https://github.com/songquanpeng/one-api/issues New-API Container: https://github.com/users/Calcium-Ion/packages/container/new-api/353967521?tag=v0.4.7.0 New-API Horizon: https://github.com/Calcium-Ion/new-api-horizon Horizon Releases: https://github.com/Calcium-Ion/new-api-horizon/releases Horizon Issues/SSE: https://github.com/Calcium-Ion/new-api-horizon/issues New-API Key Tool: https://github.com/Calcium-Ion/new-api-key-tool Bug Report #6352: https://github.com/	Portkey AI Gateway (Utama): https://github.com/Portkey-AI/gateway (npx @portkey-ai/gateway) Portkey Fork: https://github.com/stardog-union/portkey-ai-gateway Portkey Vigilnz Security Plugin: https://github.com/Portkey-AI/gateway/issues/1766 Portkey Architecture Discussion: https://github.com/Portkey-AI/gateway/discussions/1576	New-API Horizon memangkas 50% beban CPU/RAM pada konkurensi ekstrem dan +5% via optimasi SSE. Portkey-AI/gateway menambahkan dukungan rute ke 1.600+ LLM dan 50+ *guardrails* dengan konfigurasi deklaratif JSON untuk *automatic retries* dan *conditional fallbacks*.

No	Nama Sumber & Kategori	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis & Peran dalam Rantai Failover
		QuantumNous/new-api/issues/6352 LazyRouter: https://github.com/lachlanchen/LazyRouter LiteLLM: https://github.com/BerriAI/litellm		
1D.3	**ML Smart Routers, Semantic Cache & MCP Gateways**	RouteLLM (UC Berkeley): https://github.com/lm-sys/routellm RouteLLM Local Guide: https://github.com/lm-sys/RouteLLM/blob/main/examples/routing_to_local_models.md LiteLLM+RouteLLM: https://github.com/BerriAI/litellm/discussions/4753 RouterBench: https://github.com/withmartian/routerbench Weave-OS Router (<50ms Go): https://github.com/weave-os/router ClawRouter (<1ms Local): https://github.com/BlockRunAI/ClawRouter Bifrost (Go MCP Gateway): https://github.com/maximhq/bifrost AgentGateway (Rust MCP): https://github.com/	Spider Hybrid Cache Server (Rust): https://github.com/spider-rs/hybrid_cache_server & https://github.com/spider-rs/spider_remote_cache Auto-Updated LLM Capability Registry (Vision/Audio): https://github.com/spider-rs/llm_models	redis-vl-python mencegat kueri berulang dalam ~25ms melalui *semantic cache* sebelum menyentuh router. RouteLLM (\tau = 0,11593), weave-os/router (<50ms), dan ClawRouter (<1ms) memilah instruksi mudah ke model lokal dan instruksi sulit ke model frontier, sementara Langfuse menjaga batas margin biaya 75%.

No	Nama Sumber & Kategori	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis & Peran dalam Rantai Failover
		agentgateway/agentgateway Tyk Gateway: https://github.com/TykTechnologies/tyk Open-Connector (1.500+ SaaS): https://github.com/oomol-lab/open-connector Context-Mode (Kompresi 98%): https://github.com/mksglu/context-mode Valkey & RedisVL (Sumber 3): https://github.com/redis/redis-vl-python Langfuse Self-Hosted (Sumber 3): https://github.com/langfuse/langfuse		
1D.4	**Mesin Inferensi Lokal** (C++, CUDA, ROCm, Apple Metal, Low-RAM)	llama.cpp: https://github.com/ggerganov/llama.cpp (https://llama.app/install.sh) vLLM: https://github.com/vllm-project/vllm Ollama: https://github.com/ollama/ollama SGLang: https://github.com/sgl-project/sglang Edge0 (MoE 35B di 2,5 GB RAM): https://github.com/Edge0-AI/Edge0	Lemonade Server: https://lemonade-server.ai/ (lemonade pull <repo>) llama.cpp Pre-built Releases: https://github.com/ggerganov/llama.cpp/releases	Menyediakan eksekusi lokal dengan biaya nol. Edge0 memungkinkan streaming bobot model MoE 35B dari SSD hanya dalam 2,5 GB RAM melalui prediksi aktivasi *expert* satu langkah di depan.
1D.5	**Toolkit**	Refusal Direction	Huihui-AI	Mengimplementasi

No	Nama Sumber & Kategori	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis & Peran dalam Rantai Failover
	Abliteration (Penghapus Sensor Ruang Residual)	(Arditi et al.): https://github.com/andyrdt/refusal_direction FailSpy Abliterator: https://github.com/FailSpy/abliterator spkgyk Abliteration: https://github.com/spkgyk/abliteration jim-plus LLM-Abliteration (Sharded): https://github.com/jim-plus/llm-abliteration Orion-zhen Abliteration (CUDA/ROCm): https://github.com/Orion-zhen/abliteration AIAnytime Ablate (Optuna KL): https://github.com/AIAnytime/ablate Heretic v2.0 (ARA): https://github.com/p-e-w/heretic/issues/472 Math Docs: https://github.com/danielsobrado/llm_notebooks/blob/main/ABLITERATION.md	Abliteration Audit & Procedure Guide: https://github.com/adybag14-cyber/Abliteration/blob/main/docs/tools/huihui-ai.md	kan ortogonalisasi bobot permanen, *Biprojection* (--projected), *Norm-Preserving* (--normpreserve), dan *Subspace Ablation* terpandu divergensi KL tanpa memerlukan TransformerLens.
1D.6	**Perisai Keamanan Bobot Model, Guardrails & Audit Celah**	Protect AI ModelScan: https://github.com/protectai/modelscan HF Malware Docs: https://huggingface	Spider Firewall Utilities (Rust): https://github.com/spider-rs/firewall	modelscan memindai berkas Pickle, H5, dan SavedModel secara statis sebelum pemuatan untuk

No	Nama Sumber & Kategori	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Spesifikasi Teknis & Peran dalam Rantai Failover
		.co/docs/hub/other Crawl4AI SSRF Advisory: https://github.com/advisories/GHSA-wm69-2pc3-rmmf NVIDIA NeMo Guardrails & Llama Prompt Guard 2 (86M) (Sumber 3): https://github.com/NVIDIA/NeMo-Guardrails		mencegah pencurian kredensial AWS/API, sedangkan NeMo-Guardrails dan Llama Prompt Guard 2 memfilter serangan *prompt injection* masuk.

1E. Kerangka Kerja Agen Otonom, Crawler Adaptif, Gateway Omnichannel & Direktori Riset (Tanpa Pendaftaran)

Pada lapisan akuisisi data web dan agen otonom, sumber induk mencantumkan unclecode/crawl4ai namun sekaligus memperingatkan adanya kerentanan keamanan tingkat tinggi **GHSA-wm69-2pc3-rmmf** (*Unauthenticated Server-Side Request Forgery* / SSRF pada jalur /crawl/stream di server Docker). Untuk memastikan agen memiliki jalur *rolling* yang bebas dari celah SSRF tersebut sekaligus mampu menembus proteksi Cloudflare Turnstile dan perubahan struktur HTML dinamis, riset menambahkan dua mesin perayap generasi baru yang jauh lebih tangguh: **D4Vinci/Scrapling** (beserta port Rust-nya **chrisabruce/scrapling-rs**) dan ekosistem perayap konkurensi tinggi berbasis Rust **spider-rs/spider**. Scrapling dan scrapling-rs menyimpan sidik jari struktural elemen di SQLite dan menghitung skor kemiripan 12-faktor untuk merelokasi elemen secara otomatis ketika situs web mengubah nama kelas CSS atau membungkus ulang struktur DOM, lengkap dengan emulasi 135+ profil sidik jari TLS (JA3/JA4/HTTP2) dan pemecah Cloudflare Turnstile bawaan. Di sisi lain, spider-rs/spider menerapkan arsitektur *HTTP-first* yang mengalirkan halaman secara *real-time* dan hanya meluncurkan peramban Chrome tanpa kepala (*headless*) melalui crawl_smart() ketika suatu halaman terbukti membutuhkan eksekusi JavaScript.

No	Nama Sumber & Kategori	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Keunggulan Arsitektural & Peran Failover
1E.1	**Stasiun Kerja Agen Otonom & Self-Evolving Harnesses**	OpenClaw (5.380 Skills): https://github.com/openclaw/openclaw Nous Hermes Agent: https://github.com/	Hermes Install Script: https://hermes-agent.nousresearch.com/install.sh Pi Terminal Coding Agent: npm install	OpenClaw, Hermes Agent, OpenHands, dan Pi dapat langsung diarahkan ke server lokal (http://127.0.0.1:80

No	Nama Sumber & Kategori	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Keunggulan Arsitektural & Peran Failover
		NousResearch/hermes-agent HKUDS Nanobot: https://github.com/HKUDS/nanobot HF Smolagents (~1.000 baris): https://github.com/huggingface/smolagents Aider: https://github.com/Aider-AI/aider OpenHands CLI Harness (Sumber 3): https://github.com/All-Hands-AI/OpenHands	-g @earendil-works/pi-coding-agent Akash SDL Skill for Claude/Agents: https://github.com/akash-network/akash-skill	80/v1) maupun router OmniRoute dan 9Router untuk eksekusi koding otonom tanpa henti.
1E.2	**Pustaka Orkestrasi Agen Modular & Tata Kelola Runtime**	PydanticAI: https://github.com/pydantic/pydantic-ai Instructor: https://github.com/jxnl/instructor LangGraph: https://github.com/langchain-ai/langgraph Rig (Rust): https://github.com/0xPlaygrounds/rig Mastra (TS): https://github.com/mastra-ai/mastra VoltAgent (TS): https://github.com/voltagent/voltagent Microsoft Agent Governance Toolkit: https://github.com/microsoft/agent-governance-toolkit	Digunakan secara berlapis: LangGraph sebagai supervisor hierarkis 7-node, PydanticAI + Instructor untuk jaminan skema JSON, dan Microsoft Agent Governance Toolkit untuk penegakan kebijakan deterministik OWASP Agentic Top 10.	Menjamin keluaran agen selalu patuh pada skema tipe data (*type-safe*) dan setiap eksekusi kode terisolasi dengan hak akses minimum (*least-privilege*).
1E.3	**Mesin Perayap**	Crawl4AI (Utama	**Scrapling**	Mengatasi

No	Nama Sumber & Kategori	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Keunggulan Arsitektural & Peran Failover
	Web (Web Crawler) & Anti-Bot Adaptive Scrapers	di Sumber 1): https://github.com/unclecode/crawl4ai	**(Python Adaptive Scraper & Turnstile Bypass)**: https://github.com/D4Vinci/Scrapling (Docs: https://scrapling.readthedocs.io/en/latest/index.html, Docker: ghcr.io/d4vinci/scrapling:latest) **Scrapling-RS (Port Rust Native, 135+ TLS Profiles)**: https://github.com/chrisabruce/scrapling-rs **Spider-RS (Fastest Rust Crawler)**: https://github.com/spider-rs/spider & Org: https://github.com/spider-rs & Portal: https://spider.cloud/open-source/ Spider Python/Node/Multi Clients: https://github.com/spider-rs/spider-py, https://github.com/spider-rs/spider-nodejs, https://github.com/spider-rs/spider-clients Spider MCP Servers: https://github.com/	kelemahan SSRF pada Docker Crawl4AI dan kerapuhan selector CSS tradisional. Scrapling dan scrapling-rs menyimpan sidik jari struktural elemen di SQLite dan menggunakan algoritma kemiripan 12-faktor untuk menemukan kembali elemen meski situs mengubah tata letak HTML, dilengkapi pemecah Cloudflare Turnstile otomatis, penyamaran sidik jari TLS JA3/JA4 (wreq), DoH anti-bocor DNS, dan server MCP bawaan. spider-rs/spider menjalankan strategi *HTTP-first* dan hanya membuka Chrome tanpa kepala (*headless*) melalui crawl_smart() ketika halaman membutuhkan JavaScript.

No	Nama Sumber & Kategori	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Keunggulan Arsitektural & Peran Failover
			spider-rs/spider-cloud-mcp-v2 & https://github.com/spider-rs/spider-cloud-mcp-server Spider Browser/CDP/HTML2MD/UA: https://github.com/spider-rs/headless-browser, https://github.com/spider-rs/chromey, https://github.com/spider-rs/html2md, https://github.com/spider-rs/ua_generator Spider Reference Apps: https://github.com/spider-rs/spider-cloud-live-code-viewer & https://github.com/spider-rs/spider-example-knowledge-base Alternatif Tambahan: https://github.com/scrapy/scrapy, https://github.com/seleniumbase/SeleniumBase, https://github.com/omkarcloud/botasaurus, https://github.com/scrapfly/scrapfly-scrapers	
1E.4	**Gateway Omnichannel Mandiri & Template**	WAHA — WhatsApp HTTP API (Sumber 3): https://github.com/	Digunakan bersama Hermes Agent dan Nanobot untuk	Menghilangkan biaya langganan bulanan SaaS gateway pesan

No	Nama Sumber & Kategori	Tautan Primer (Eksisting dari Sumber Induk)	Tautan Alternatif & Superior Baru (Hasil Riset untuk Auto-Rolling)	Keunggulan Arsitektural & Peran Failover
	Antarmuka Web	devlikeapro/waha Aceternity UI (Sumber 3): https://ui.aceternity.com/ Magic UI (Sumber 3): https://magicui.design/	menghubungkan agen secara gratis ke WhatsApp, Telegram, Discord, Slack, Signal, dan Matrix, serta merakit antarmuka web bergaya *Futuristic Luxury*.	pihak ketiga melalui kontainer Docker mandiri.
1E.5	**Direktori Riset, Kurasi Agen & Katalog Layanan Free-Tier**	Awesome Model Routing: https://github.com/yenanjing/awesome-model-routing Awesome LLM Routing: https://github.com/dstripelis/Awesome-LLM-Routing Awesome AI Agents (Aloth): https://github.com/aloth/awesome-ai-agents Awesome Agentic AI (Mfornos): https://github.com/mfornos/awesome-agentic-ai Awesome Agentic AI (Adriannoes): https://github.com/adriannoes/awesome-agentic-ai Awesome AI Agents (Slavakurilyak): https://github.com/slavakurilyak/awesome-ai-agents Awesome AI Agents (E2B): https://github.com/	Topik Web Scraping Python: https://github.com/topics/web-scraping-python Topik Spider Cloud: https://github.com/topics/spider-cloud Direktori Evaluasi API Agentik: https://apis.io/providers/spider-cloud/	Berfungsi sebagai sumber penemuan otomatis (*automated discovery registries*) yang dapat dipindai secara berkala oleh agen perayap untuk menemukan layanan *free-tier* baru ketika penyedia lama mengubah ketentuan layanan.